

AI-Native 优化器

研究版图、前沿进展与电网研究路线

顶级学术调研报告 · 立项与博士招聘版

覆盖：自动优化建模、学习增强精确求解器、神经与生成式组合优化、可微优化、算法发现、GPU 原生求解及电网交叉

证据截止	2026-07-14
文献矩阵	100 项核心论文、系统与开源项目
研究结论	AI 生成/选择 + 数学修复/认证 + OOD 回退
重点领域	SCUC / OPF / SCOPF / 异构 CPU-GPU 求解

本报告区分作者声称、同行评审证据与独立研判；对预印本、许可证不清和评测污染风险均作降级标注。

目录

正文按研究谱系、证据成熟度、研究缺口和电网路线组织；PDF 书签可用于快速跳转。

- 摘要
- 1. 研究对象、术语和边界
- 2. 调研方法与证据标准
- 3. 领域演化：从“学一个启发式”到“优化系统闭环”
- 4. 高影响力文献：成熟主线与引用结构
- 5. 2025-2026 前沿工作：应重点跟踪什么
- 6. 六条核心技术主线的深入分析
- 7. GPU/加速器原生求解器：底座、边界与机会
- 8. 开源与复现：哪些能真正借鉴
- 9. 知名学者、机构与研究团队
- 10. 当前研究热点：2026 年的真实“热区”
- 11. 关键研究 gaps：可以形成博士课题的问题
- 12. 电网 AI-Native 优化：现状、机会与建议架构
- 13. 哪些方向最快拿到结果，哪些值得长期投入
- 14. 建议的三阶段研究计划
- 15. 博士招聘与团队配置
- 16. 顶级研究应采用的实验协议
- 17. 风险清单与立项判断
- 18. 结论
- 附录 A：建议优先精读的 20 篇/项目
- 附录 B：建议持续跟踪的平台

摘要

“AI-Native 优化器”尚不是一个定义稳定的学术门类。当前被这一名称覆盖的工作，实际上分布在七条技术谱系：大语言模型自动建模与优化智能体、学习增强的精确求解器、神经组合优化、生成式解生成、可微优化与决策聚焦学习、Learning-to-Optimize/学习型数值算法，以及 GPU/加速器原生求解器。它们的目标、可靠性和产业成熟度差异很大，不能用一个排行榜概括。

本报告的核心结论是：

- 截至 2026 年，尚不存在一个经多类真实工业问题独立验证、可普遍替代 Gurobi、SCIP、HiGHS、COPT 等成熟求解器的通用“AI 原生求解器内核”。近期最可信的形态是“AI 生成或选择策略 + 数学求解器修复与认证 + 置信度/OOD 检测 + 安全回退”。
- 短期产业价值最高的是 learning-augmented exact solver，而不是纯神经替代。实例级参数配置、presolve、separator/cut 策略、约束筛选、置信度变量固定、LNS 和完整 primal-dual warm start，既能利用重复实例分布，又能保留可行性和最优性证书。
- 2024-2026 年最明显的研究迁移是：从单个 GNN 模块转向求解器全生命周期编排；从自回归神经解码转向 diffusion/flow 多候选生成；从 outcome-only 转向 solver-in-the-loop 与过程监督；从单问题模型转向跨 MILP 类别的预训练；从“平均更快”转向泛化、对称性、校准和安全回退。
- LLM 自动建模是“AI-native optimization system”最活跃的新分支，但仍不是数值求解器。它能显著降低模型构建成本；最大未解问题不是代码能否运行，而是模型是否忠实表达业务语义、是否遗漏约束、是否使用数值稳定且可扩展的 formulation。
- GPU-native solver 是关键底座，但 GPU 不等于 AI。cuPDLPx、MPAX、PDHCG-II、PDCS、MadNLP/ExaModelsPower、cuOpt 等扩展了可批量、可微和超大规模优化能力。最新大规模 UC 研究甚至显示：激进 presolve 后 CPU 在 45/45 个案例上均早于 GPU 完成，说明“学习型 CPU/GPU/算法/预处理路由”比固定选择 GPU 更有研究价值。
- 电网是形成独立研究领域的优质切入口。它同时具备严格物理约束、重复求解分布、成熟求解器、公开基准、强安全需求和清晰验证器；但目前没有成熟的端到端 AI-native AC-SCUC/SCOPF 系统。机会集中在可认证 SCUC 约束筛选、安全 warm start、异构求解路由、跨拓扑 OPF 表征、Grid-Space/solver-trace benchmark，以及 typed optimization IR 与物理验证。
- 若只启动三条共享同一数据底座的主线，建议：
 - SCUC 的可认证约束筛选、solver 配置与安全 warm start；
 - GridBench/Grid-Space：电网优化数据、文档、模型、solver trace 与 OOD 评测基础设施；
 - 拓扑图 × 时间图的连续-整数生成模型，并以精确求解器 correction/certificate 收口。

本报告建议以 5-7 名互补博士构成团队，而不是只招聘大模型方向：数学规划与求解器、电力系统优化、图学习与基础模型、生成模型、可微优化与学习理论、GPU 数值计算、形式化验证/系统各形成一个支点。

1. 研究对象、术语和边界

1.1 操作性定义

本报告将 AI-Native 优化器定义为：

在数学规划或组合优化的建模、算法设计、求解器内部决策、候选解生成、数值迭代、硬件调度、验证和持续维护中，将可学习模型置于核心闭环，并利用可执行目标或数学约束产生反馈的优化系统。

这个定义强调三个条件：

- 对象是运筹优化/数学规划，而不是 Adam、SGD 等神经网络训练 optimizer 的泛称；
- AI 必须进入优化生命周期的关键环节，而不只是做前置预测；
- 对高风险场景，最终系统必须说明可行性、最优性界、失败模式和回退机制。

1.2 七条研究谱系

谱系	AI 位于哪里	代表任务	典型输出	当前成熟度
LLM/Agentic OR	自然语言到模型、代码、解释与修改	NL2Opt、Build/Revise/Explain	数学模型、求解代码、审计记录	2.5/5
学习增强精确求解器	B&B/B&C、presolve、cut、配置、LNS	MILP/SCUC	solver policy、warm start、reduction	3.5/5
神经组合优化	直接构造或改进离散解	TSP、VRP、MIS、调度	近似可行解	3/5（窄域）
生成式求解	diffusion/flow/GFlowNet 生成候选	TSP、ILP/MILP	多候选解、变量分布	2.5/5
可微优化/DFL	优化器嵌入训练图或决策损失	预测-优化、控制、能源调度	梯度、决策模型	3.5/5
L2O/学习型数值算法	更新规则、预条件器、Krylov/IPM 状态	LP/QP/NLP、线性系统	迭代器、数值 warm start	2.5/5
GPU/accelerator-native	数值内核、批量/可微/HPC 底座	LP/QP/SOCP/NLP、松弛	高吞吐求解能力	4/5（但非 AI 本身）

成熟度含义：1 为概念验证，3 为可复现研究系统，5 为跨场景稳定工业基础设施。这里的分数是本报告依据公开证据做出的综合判断，不是论文作者自评。

1.3 四种可靠性形态

形态	例子	是否保留 exactness/证书	适合部署程度
安全增强	学 branching、排序、配置，错误时回退默认策略	通常可以	高
生成 + 修复 + 认证	AI 产出候选或部分固定，solver 修复并证明	可以	最高
纯神经代理	端到端预测 OPF/组合解	通常不可以	低至中
优化层/决策损失	solver 用于反向传播	与“求解更快”无必然关系	研究和特定应用较成熟

2. 调研方法与证据标准

2.1 数据源与检索策略

检索覆盖 arXiv、OpenReview、PMLR、NeurIPS/ICLR/ICML/AAAI proceedings、INFORMS/Management Science/Operations Research、JMLR/JAIR、Nature、官方项目页、作者 GitHub/Hugging Face，以及 Semantic Scholar 引用记录。检索词除 “AI-native optimizer” 外，还包含：

- learning to optimize / learning-augmented optimization;
- machine learning for combinatorial optimization;
- learning to branch/cut/presolve/configure/LNS;
- neural combinatorial optimization / diffusion solver / flow matching MILP;
- differentiable optimization / decision-focused learning / predict-then-optimize;
- LLM for operations research / optimization modeling / algorithm discovery;
- GPU LP/QP/MIP/OPF/SCUC / accelerator-native solver。

检索截止到 **2026-07-14**。2026 年顶会论文按 OpenReview 的最终 decision/status 认定；只有投稿页而无接收决定的工作，一律标为“投稿/预印本”，不写成已发表。

2.2 纳入和排除

纳入：

- 对建模、求解器策略、候选解、优化层、数值迭代或硬件路由有实质贡献；
- 重要同行评审工作，或 2025-2026 年具有明显前沿价值且提供充分技术材料的预印本；
- 能通过公开代码、数据、模型或清晰实验协议进一步核查的项目。

排除或降权：

- 仅使用优化器训练普通神经网络、与数学规划无关的 optimizer；
- 只做预测，未评价下游决策或求解；
- 只在极小玩具问题上演示、没有强经典基线；
- 已撤稿、仅 workshop 摘要或状态不清但声称顶会接收；
- 公开仓库无 LICENSE 却宣称“开源可商用”。

2.3 证据等级

等级	标准
A+	正式同行评审；官方代码/数据可用；有多数据集、强基线或独立评测
A	正式同行评审；证据充分，但代码/数据不完整或任务范围较窄
B+	顶会已接收或高质量期刊在印；有公开实现，但许可/复现/扩展性仍有缺口
B	已接收但无完整实现，或强预印本已有较完整公开资产
C+	预印本/企业白皮书；有代码，可做研究复现
C	预印本；代码、数据或独立复核不足

证据等级衡量“可以多大程度据此做投资和复用”，不等同于学术新颖性。

2.4 引用量口径

高被引表使用 Semantic Scholar canonical paper 的 `citationCount`，查询日为 2026-07-14。引用量会变化，且不同数据库对 arXiv/会议/期刊版本的合并不同；因此这里用于识别历史影响力，而不是比较当前性能。2024-2026 年前沿论文单独评价，避免“时间窗口偏差”。

3. 领域演化：从“学一个启发式”到“优化系统闭环”

3.1 2010-2016：算法展开、可变长度输出和早期 learned policy

- [LISTA](#) 将 ISTA 展开为固定深度可训练网络，奠定 algorithm unrolling。
- [Pointer Networks](#) 解决组合输出长度随输入变化的问题。
- [Learning to Learn by Gradient Descent](#) 用 RNN 学更新规则。
- [Neural Combinatorial Optimization with RL](#) 将 Pointer Network 与 REINFORCE 结合，学习 TSP 构造策略。
- [Learning to Branch in Mixed Integer Programming](#) 将 imitation/ranking 引入 MIP branching。

这一时期解决的是“可否学习算法动作”，但训练分布、规模泛化和可行性保证还不是中心问题。

3.2 2017-2020：优化器成为网络层，MILP 成为二部图

- [OptNet](#) 通过 KKT 隐式微分把 QP 变成网络层。
- [Task-based End-to-end Model Learning](#) 和 [Smart Predict, then Optimize](#) 把训练目标从预测误差转向决策损失。
- [Exact CO with GCNs](#) 将 MILP 表示为变量-约束二部图，成为后续 MILP GNN 的标准范式。
- [Differentiable Convex Optimization Layers](#) 将 disciplined parametrized programs 统一为可微层。
- Neural Diving、learning-to-cut 和学习型 LNS 开始接入完整求解流程。

同一时期出现关键反思：GNN 节点决策的 GPU/CPU 传输和 callback 成本可能吞掉节点数收益。[Hybrid Models for Learning to Branch](#) 直接证明纯 GNN 在 CPU 场景并不自然占优，并提出廉价混合模型。

3.3 2021-2023：全流程求解器学习、基准化和可行性修正

- branching、node comparison、cut selection/removal、separator configuration、LNS、solver configuration 都出现学习方法。
- [ML4CO Competition](#)、SCIP/PySCIPOpt/Ecole 使任务和接口逐步标准化。
- [POMO](#) 利用多对称起点，[DIFUSCO](#) 将图扩散引入 TSP/MIS。
- [DC3](#) 用可微 completion/correction 改善 hard-constraint 可行性。
- [What's Wrong with Deep Learning in Tree Search for CO](#) 以复现实验显示某些公开“神经树搜索”的性能主要来自传统 kernelization，GNN 可被随机值替代。这篇工作对领域方法论非常重要：必须做随机/禁用学习模块消融，并与强经典实现比较。

3.4 2024-2026：基础模型、生成式求解、solver-RL 和算法发现

- LLM 从提示工程走向专用模型、RL with verifiable rewards、过程审计和全生命周期 workspace。
- MILP 学习从单任务 GNN 走向跨类别数据合成、foundation representation、对称性和理论样本复杂度。
- diffusion 向 flow matching、连续-整数联合生成、少步采样和 geometry-aware transport 演进。
- FunSearch/EoH/ReEvo/AlphaEvolve 一类系统让 LLM 直接搜索可执行算法代码。
- GPU 数值栈从单一 CUDA LP 原型扩展到 JAX 可微批量 LP/QP、GPU QP/锥规划、GPU ACOPF、多 GPU 场景优化。

总体演进可概括为：

单个学习策略
→ 学习增强的求解器模块
→ 候选生成 + 修复 + 认证
→ 多模块 solver orchestration
→ 建模、求解、验证、解释、修订、监控的长期优化代理

4. 高影响力文献：成熟主线与引用结构

4.1 跨谱系高被引基础工作

排名	工作	年份	主要谱系	约引用数
1	Pointer Networks	2015	神经 CO/序列生成	3,505
2	Learning to Learn by Gradient Descent	2016	learned optimizer	2,218
3	LISTA	2010	algorithm unrolling	2,058
4	Neural Combinatorial Optimization with RL	2016/17	神经 CO	1,847
5	Machine Learning for CO: A Methodological Tour d'Horizon	2021	领域综述	1,832
6	Learning CO Algorithms over Graphs	2017	GNN/RL CO	1,742
7	Attention, Learn to Solve Routing Problems	2019	神经路由	1,648
8	OptNet	2017	可微优化	1,269
9	Differentiable Convex Optimization Layers	2019	可微优化	886
10	Smart Predict, then Optimize	2022	DFL	879
11	Exact CO with GCNs	2019	learning-to-branch	645
12	POMO	2020	神经 CO	636
13	Melding the Data-Decisions Pipeline	2019	DFL	387
14	Learning to Optimize: A Primer and Benchmark	2022	L2O	357
15	Differentiation of Blackbox CO Solvers	2020	可微组合优化	350
16	Solving MIPs Using Neural Networks	2020	Neural Diving/branching	321
17	SATNet	2019	可微离散层	319
18	DIFUSCO	2023	生成式 CO	302

解释：Pointer Networks 和 learned optimizer 的部分引用来自 NLP、meta-learning 等外部领域；高引用不表示当前解质量最好。对求解器工作，完整 wall-clock、生产接口、独立复现和许可证往往比引用量更重要。

4.2 LLM/算法发现子领域的高被引工作

工作	年份/状态	约引用数	证据评价
FunSearch	Nature 2023	1,073	A+；重大概念影响，生产系统未完整开放
OPRO	ICLR 2024	959	A+；通用 CO 上仍弱于专用算法
Eureka	ICLR 2024	663	A+；主要验证在机器人 reward design
AlphaEvolve	2025 白皮书	630	C；高影响、非同行评审、系统不开放
FoH	ICML 2024 Oral	298	A+；易对有限实例过拟合
ReEvo	NeurIPS 2024	292	A+；反思未校准、存在 winner's curse
ORLM	Operations Research 2025	134	A+；专用 OR 模型的代表
OptiMUS	ICML 2024	108	A+；自动建模代理代表

5. 2025-2026 前沿工作：应重点跟踪什么

下表按“已正式接收”和“预印本/新系统”分开，避免把前沿热度误写成成熟结论。

工作	状态	关键贡献	主要限制	证据
Towards Foundation Models for MILP	ICLR 2025	MILP-Evolve 合成跨类任务，做 branching/gap/alignment	合成类别与真实语义覆盖仍有限	A/B+
Apollo-MILP	ICLR 2025	prediction-correction-confidence fixing	多次修正有额外成本，仍依赖同分布解池	A
OptMATH	ICML 2025	53 类生成器、20 万级双向数据	生成器与 verifier 可能共享偏差	A+
Large Language Model-driven LNS	ICML 2025	双层自进化 LLM 发现 MILP 邻域策略	作者场景外泛化、总计算成本需独立复核	A
ORLM	Operations Research 2025	OR-Instruct、IndustryOR、7B/8B 专用模型	复杂工业准确率仍不足；评测与 COPT 耦合	A+
SIRL	NeurIPS 2025	solver-informed RLVR，奖励语法/可行/目标/LP 表达	目标相同不代表语义忠实	B+
FMIP	ICLR 2026 Poster	联合连续-整数 flow matching，平均 primal gap 降低 41.34%	超大实例下降，仍需求解器修复/认证	B+
Constraint Matters	ICLR 2026 Poster	学习 tight constraints 做约束侧模型缩减	依赖最优标签；错误等式化风险需强修复	B+
LLM4Branch	ICML 2026	LLM 生成可执行 branching skeleton，零阶优化参数，只用少量实例	跨 solver/问题族和尾部退化待验证	B+
Provably Data-driven Lagrangian Relaxation	ICML 2026	对学习 LR multiplier 给出统计理论，直接关联 UC 等分解问题	理论界与真实 wall-clock 间仍有距离	A/B+
Draft-and-Audit RL	ICML 2026	同一策略先起草，再按 OR 错误清单审计	两轮审核及终端奖励仍不能证明语义正确	B
StepORLM	ICLR 2026	policy 与生成式过程奖励模型共同进化	过程 judge 可奖励“像专家”的错误过程	B+
OPT-Engine	ICML 2026	可控复杂度 LP/MILP benchmark，发现约束建模是瓶颈	模板化合成任务；依赖 Gurobi	B+
CycFlow	2026 预印本	将欧氏 TSP transport 到圆环，避开边矩阵	强几何假设，不能外推到通用 CO	C
Aqora-Opt	2026 预印本	去中心化多团队辩论 + 多类持久记忆	公开实现存在 benchmark 与 solution memory 重叠风险	C+
OR-Space	2026 预印本	Build/Revise/Explain 的工业 workspace benchmark	合成 workspace；数据为 CC BY-NC	C+
GraphBU	2026 预印本	bottom-up MILP graph 表征/预训练新方向	尚无完整稳定官方代码和独立复现	C
LUMINA	ICLR 2026 Workshop	topology-transferable ACOPF foundation model 原则	workshop 证据；稳定代码/认证链不足	C+
Towards Systematic Generalization for Power Grid Optimization	2026 预印本	ACOPF 与 SCUC 共享图 backbone，测试跨拓扑	仍需严格 checker、真实 OOD 和公开复现	C

工作	状态	关键贡献	主要限制	证据
Rapid Concurrent GPU-CPU UC	2026 预印本	大规模 UC 的 CPU/GPU 并行 portfolio；揭示 presolve 改变赢家	Gurobi beta/闭源、无公开实现	C

重要审计提示： 对 Agora-Opt，本报告将其看作值得研究的“多代理 + 记忆”架构，而不直接接受其公开总体分数。代码路径中的持久 solution/debug/debate memory 与 benchmark 使用方式需要 clean-room 复评：冻结记忆、按模板/图同构去重、严格时间切分，并在未见过的模型族上重新测试。此处是可复现性风险判断，不是对研究动机或作者意图的推断。

6. 六条核心技术主线的深入分析

6.1 LLM 自动建模与 Optimization Agents

代表链条：

NL4Opt → OptiMUS / Chain-of-Experts → ORLM / LLMOPT
→ OptiBench / OptMATH → SIRL / StepORLM
→ Draft-and-Audit / OPT-Engine → OR-Space / Agora-Opt

已取得的能力

- 将规范化自然语言转换为 LP/MILP 数学式和 Pyomo/Gurobi/COPT/OR-Tools 代码；
- 运行 solver、读取错误、修正变量/约束/数据接口；
- 通过反向生成构建训练数据；
- 用求解器作为可验证 reward 做 RLVR；
- 在多轮中 Build、Revise、Explain，开始覆盖优化工程生命周期。

尚未解决的核心问题

1. **语义正确性。** 程序可运行、解可行、目标值一致，仍可能遗漏业务约束或把错误模型“正确求解”。
2. **需求不完备。** 公开题目通常已给足信息；真实需求会遗漏单位、时间粒度、异常规则、优先级和例外。
3. **formulation quality。** 现有评测很少检查 big-M 紧致性、LP relaxation gap、对称性、数值条件、稀疏性、节点数和 p99 runtime。
4. **数据污染。** 大量题目来自少数 canonical 模型的改写；字符串去重不足以识别模板和数学图同构近邻。
5. **多代理相关错误。** 多个 agent 常共享 backbone、训练数据和提示，不是独立证据；辩论会放大共同盲点。
6. **治理。** 企业模型需要版本、数据 lineage、回归测试、审计、沙箱、回滚和责任链。

近期最值得用的资产

- [ORLM](#)：Apache-2.0；开放专用模型路线，但训练数据仅部分公开。
- [OptiMUS](#)：MIT；模块化 agent 基线；NLP4LP 数据含非商业限制。
- [OptMATH](#)：Apache-2.0；高质量合成与训练基线。
- [ReSocratic](#)：Apache-2.0；端到端 benchmark/data synthesis。
- [SIRL/StepORLM](#)：适合学术复现；仓库许可证不清时不可直接视为商用开源。

本报告判断： 最快形成可信成果的不是继续堆叠 agent，而是建立“typed IR + 语义单元测试 + 物理/业务反例生成 + solver certificate + 主动澄清”的双重验证闭环。

6.2 学习增强的精确求解器

研究对象已覆盖：

presolve → relaxation → separator/cut → branching/node
→ primal heuristic/LNS → restart/configuration → numerical solve

为什么它最接近产业价值

- AI 错误通常影响速度而不是正确性；
- 默认策略可以无缝回退；
- 重复求解同类实例时有明确数据分布；
- 最终可由 B&B/B&C、checker 或 constraint generation 认证；
- 可用小模型、树模型或符号表达式降低 callback 成本。

关键代表

- [learn2branch](#): 二部图 GNN branching 的基准。
- [Hybrid Learn2Branch](#): 强调 CPU 推理成本。
- [Neural MIP Solving](#): Neural Diving/branching, 大规模工业实例经验。
- [Learning to Configure Separators](#): 实例级 B&C 配置。
- L2P-MIP、Symb4CO、SymILO、Apollo-MILP、ConPaS、FMIP、LLM4Branch: 分别推进 presolve、可编译规则、对称标签、预测修正、变量固定、生成 warm start 和自动策略发现。

最大技术问题

- 求解器模块强耦合，局部 surrogate 指标改善可能使整体 wall-clock 变差；
- strong branching、lookahead cuts、最优解池和 traces 的标签代价高；
- solver 版本、参数、线程、硬件改变会导致策略漂移；
- 论文常不计算训练数据生成成本要运行多少次生产任务才能回本；
- 极端难例、timeout 和尾部退化比平均加速更重要。

6.3 神经组合优化与生成式解生成

自回归路线由 Pointer Network、Attention Model、POMO 发展；生成路线由 DIFUSCO、DiffUCO、GFlowNet/GFACS、DISCO、FMIP、CycFlow 推进。

当前热点

- 多模态解分布，而不是单一监督标签；
- 并行生成变量或边的概率图；
- objective/constraint guidance；
- 联合连续-离散变量；
- 生成多个候选供 solver/LNS 选择；
- 降低 diffusion 步数和 $O(n^2)$ edge heatmap 内存。

客观定位

这类方法在 TSP/CVRP/MIS 等结构固定、可大量生成训练实例的问题上有价值；但通用 MILP 的变量类型、约束语义、尺度和数值结构远更异质。现阶段最可靠的定位是：

高质量 candidate/warm-start distribution，配合 repair、local branching、sub-MIP 和 exact certificate；不是独立认证求解器。

6.4 可微优化与 Decision-Focused Learning

这条路线解决的是“预测如何服务最终决策”，并不等同于加速 solver。

- OptNet/qpth: QP 层；
- CVXPYlayers: DPP 可表达凸优化层；
- SPO/SPO+: 以决策 regret 训练预测；
- blackbox differentiation: 给不可微组合求解器构造 surrogate backward；

- perturbed optimizers: 用随机扰动平滑 argmin;
- PyEPO: 统一 predict-then-optimize 实验接口。

它对电网的直接价值很高: 负荷、可再生、故障概率预测应以最终调度成本、备用不足、拥塞、弃电和风险为训练目标, 而不是只最小化 MSE。主要风险是训练中反复求解成本、active-set 不连续、梯度偏差、求解器病态和多阶段随机问题的规模。

6.5 Learning-to-Optimize 与学习型数值线性代数

该谱系包括:

- algorithm unrolling (LISTA) ;
- learned optimizer (LSTM/VeLO/ μ LO) ;
- IPM-LSTM;
- learned preconditioner、Neural Krylov、factorization reuse;
- 预测完整 primal-dual-barrier state 的 warm start。

其长期价值在于 ACOPT、SQP/IPM、锥松弛和场景优化都会反复求解相似 KKT 系统。相比直接预测最终解, 学习预条件器、低维不变子空间或完整 primal-dual 状态更容易与数值算法结合。但必须测量网络推理开销、残差、病态/退化鲁棒性和 OOD 稳定性。

6.6 LLM 驱动算法发现

代表路线:

- [FunSearch](#): 程序数据库、island evolution、自动 evaluator; 公开的是简化参考实现。
- [EoH](#): 同时进化自然语言思想和代码, MIT。
- [ReEvo](#): 用反思形成 verbal gradient, MIT。
- [LLaMEA](#): 进化完整 metaheuristic 类, MIT。
- [LLM4AD](#): BSD-2-Clause 统一实验平台。
- [ShinkaEvolve](#): 多 LLM bandit、新颖性过滤, Apache-2.0。
- AlphaEvolve: 影响显著, 但生产系统、算力和模型未开放。

真正的科学问题

- 自适应搜索反复试 benchmark, 如何修正 multiple testing 和 winner's curse?
- heuristic 是否跨实例、规模、硬件、求解器版本泛化?
- evaluator 一次耗时数小时、有噪声时, 怎样做多保真预算分配?
- 如何证明生成策略不破坏 branch-and-cut 合法性或安全约束?
- 如何区分“调好超参数”与“发现了新算法思想”?

电网最适合的切入不是让 LLM 直接生成完整求解器, 而是搜索有明确安全外壳的策略: SCUC 邻域、分解、约束排序、contingency screening、warm-start、cut/branching score 和 solver portfolio。

7. GPU/加速器原生求解器: 底座、边界与机会

7.1 直接可用的开放资产

项目	任务	许可证/状态	推荐用途	关键限制
HiGHS	LP/QP/MIP	MIT, 成熟	开源 CPU 基线和兜底	GPU first-order 仍演进中
cuPDLPx	GPU LP	Apache-2.0, 活跃研究	DCOPF、UC 根松弛、Benders 子问题	低/中精度更有优势
MPAX	JAX LP/QP, 可微、batch、多设备	MIT	DFL、批量 DCOPF/QP	无整数、无非凸 AC
PDHCG-II	GPU convex QP	Apache-2.0	二次 ED、DCOPF-QP、MPC	无整数/非凸 AC
PDCS	GPU 锥规划	Apache-2.0, 早期	SOCF-OPF、鲁棒/机会约束	工程成熟度仍低
NVIDIA cuOpt	LP/QP/VRP, MILP/QCQP/SOCF beta	Apache-2.0	GPU 开源对照、可行解搜索	MIP 最优性证明仍在开发
MadNLP + ExaModelS	GPU NLP/自动微分	MIT	ACOPF、多时段非凸 NLP	只能保证局部解
ExaModelsPower	OPF/固定 UC 后 SCOPF/储能	MIT	GPU 电网优化直接基线	紧容差、小问题优势会变化
COPT 8.0	LP/MILP/QP/锥/SDP/NLP	闭源商业	国产商业强基线	不应与 COPT-Public 开源项目混淆

7.2 不能省略的评测事实

- 1. GPU 优势最稳定在超大、稀疏、矩阵向量计算占主导、低到中精度的 LP/QP/NLP。
- 2. SCUC/MILP 的 presolve、crossover、simplex cleanup、动态 cuts 和 B&B 仍大量依赖 CPU。
- 3. first-order 方法必须同时报告绝对/相对 KKT residual、可行性、目标差和高精度清理时间。
- 4. 端到端时间应包含建模、数据转换、presolve、CPU-GPU 传输、求解、crossover、repair、checker 和 certificate。
- 5. ACOPF 与 IPOPT/MadNLP 的目标差只是相对某个局部解，不能称全局 optimality gap。

7.3 最有价值的研究机会：学习型异构路由

[Rapid Concurrent GPU-CPU UC](#) 在 6,049-bus、数百万变量/约束的 45 个 UC 案例上给出一个反直觉结果：默认设置下 GPU 先完成 33/45；激进 presolve 后 CPU 45/45 全部先完成。它说明：

研究目标不应是“永远让 GPU 赢”，而应学习何时选择 CPU/GPU、PDHG/barrier/simplex、presolve 强度、容差、混合精度和 crossover。

该方向风险低、证书不变、3-9 个月即可形成可靠成果，是本报告最推荐的快速课题之一。

8. 开源与复现：哪些能真正借鉴

8.1 “公开代码”与“开源”不是同义词

只有明确 LICENSE 才能判断复用范围。仓库无许可证时，默认仅可阅读，不应复制、修改、分发或商业化。数据许可证还需单独检查；代码 Apache/MIT 不自动覆盖训练数据、基础模型权重或商业 solver。

8.2 推荐栈

目标	首选开放栈	备注
通用 learning-augmented MILP	SCIP + PySCIPOpt + Ecole + HiGHS	便于 callback、trace、exact fallback
OR 自动建模	ORLM + OptMATH + OptiMUS + ReSocratic	核对模型/数据的各自许可证
可微/DFL	CVXPYlayers + PyEPO + MPAX	从 LP/QP/DCOPF 开始最稳妥
神经 CO	Attention Model/POMO + DIFUSCO	先做窄问题和严格经典 baseline
算法发现	EoH + ReEvo + LLaMEA + LLM4AD	evaluator/沙箱和统计校正是重点
SCUC	UnitCommitment.jl + PGLIB-UC + HiGHS	独立 checker 适合安全研究
OPF 数据/代理	PGLearn + ML4OPF + GridFM DataKit	建立 topology/time/extreme OOD split
GPU LP/QP/锥	cuPDLpx + MPAX + PDHCG-II + PDCS	HiGHS/商业 solver 做同容差对照
GPU ACOPF	PowerModels + ExaModelsPower + MadNLP	记录局部性和 KKT residual
闭环电网运行	Grid2Op	不能替代静态 OPF/SCUC benchmark

8.3 许可证风险样例

- ORLM、OptMATH、ReSocratic、cuPDLpx、PDHCG-II、PDCS、ShinkaEvolve：许可证清楚，适合建立研究基线。
 - SIRL、StepORLM、LLMOPT、Agora-Opt、OPT-Engine、FPL-OPF 等部分仓库未见明确 LICENSE；不能仅因 GitHub 可访问就称“可商用开源”。
 - OR-Space/NLP4LP 等数据带 NC 限制；适合学术研究，商业复用需重新授权。
 - COPT 主产品和 Gurobi 是商业闭源；COPT-Public 的 MIT/Apache 项目不覆盖主求解器。
 - OPFData 等大型数据的许可页不清晰，应先完成数据治理再训练模型。
- 完整可筛选条目见同目录的 [AI_Native_Optimizer_Literature_Matrix_2026.csv](#)。

9. 知名学者、机构与研究团队

9.1 通用 MILP、solver learning 与 optimization foundation model

团队	代表学者/项目	核心优势
Mila / Polytechnique Montréal / ds4dm	Andrea Lodi、Yoshua Bengio、Maxime Gasse、Didier Chételat、Laurent Charlin	GNN branching、hybrid policy、node comparison、ML4CO
Google DeepMind / Google Research	Vinod Nair、Nicolas Sonnerat、Oriol Vinyals、Yujia Li 等	Neural Diving、工业 MILP、learned optimizer、算法发现
MIT LIDS/CEE 与 MSR	Cathy Wu、Sirui Li、Ishai Menache、Konstantina Mellou 等	separator/configuration、MILP foundation model、OptiGuide/OptiMind
USTC-华为诺亚-上海交大	Jie Wang、Feng Wu、Jianye Hao、Xijun Li、Junchi Yan 等	Symb4CO、Apollo-MILP、L2P-MIP、学习型数值算法
上海交大-杉数-Stanford/Princeton 合作网络	葛冬冬、叶荫宇、王梦迪、Qi Huangfu、Hongpei Li 等	COPT、GPU 优化、ORLM/SIRL/StepORLM、FMIP
ZIB/SCIP	SCIP、PySCIPOpt、Ecole 维护者	开源 exact solver 与 ML 实验接口

9.2 可微优化与 Decision-Focused Learning

团队	代表学者	代表贡献
CMU	J. Zico Kolter、Brandon Amos、Priya Donti	OptNet、SATNet、DC3、能源决策
Stanford Convex Optimization Group	Stephen Boyd、Akshay Agrawal、Steven Diamond	CVXPY、DPP、CVXPYlayers
Columbia / UC Berkeley	Adam Elmachtoub、Paul Grigas	SPO/SPO+、contextual optimization
VUB/KU Leuven / Melbourne	Jayanta Mandi、Tias Guns、Peter Stuckey	hard CO 的 DFL、benchmark、缓存/近似梯度
MPI-IS	Georg Martius、Michal Rolínek、Marin Vlastelica、Anselm Paulus	blackbox differentiation、NeuralCut
Google Research / INRIA / ENS	Mathieu Blondel、Quentin Berthet、Francis Bach、Marco Cuturi	perturbed optimizers、implicit differentiation

9.3 神经 CO 与算法发现

团队	代表人物/项目	方向
A*STAR/NTU/AI4CO/KAIST	Zhiguang Cao、Wen Song、Jinkyoo Park 等	POMO 后续、DeepACO、GFlowNet、ReEvo
CMU	Zhiqing Sun、Yiming Yang	DIFUSCO
JKU Linz	Sepp Hochreiter、Sebastian Sanokowski、Sebastian Lehner	无监督 diffusion CO
CityU/SUSTech	Qingfu Zhang、Fei Liu 等	EoH、EoH-S、LLM4AD
Google DeepMind	FunSearch、AlphaEvolve 团队	可执行程序搜索、数学和系统算法发现
Sakana AI	ShinkaEvolve	多模型进化代码搜索
Leiden LIACS	LLaMEA 团队	LLM 进化 metaheuristics

9.4 GPU 优化与电网

团队	项目/代表人物	方向
MIT Lu Lab	Haihao Lu、cuPDLpx、MPAX	GPU first-order LP/QP、可微批量求解
University of Edinburgh	Julian Hall、HiGHS/HiPDLP	高可靠开源 LP/MIP、能源系统合作
MadNLP/ExaModels	Sungho Shin、François Picaud、Mihai Anitescu 等	GPU NLP、ACOPF/SCOPF、多时段优化
LANL ANSI	Carleton Coffrin、PowerModels/PGLib	OPF 建模、凸松弛、公开基准
Argonne CEEESA	Alinson Xavier、Feng Qiu、UnitCommitment.jl	SCUC、市场清算、独立验证
NSF AI4OPT / Georgia Tech	Pascal Van Hentenryck、Mathieu Tanneau、Dan Molzahn 等	PGLearn/ML4OPF、优化代理、能源/电网
RTE France	Benjamin Donnot、Grid2Op/L2RPN	闭环运行、拓扑控制、安全 RL
LF Energy GridFM	IBM、Argonne、Le Xie 等	电网 foundation model 和开放数据

9.5 葛冬冬团队的客观定位

葛冬冬团队形成了少见的连续链条：经典 LP/MILP/锥优化与 COPT → GPU 数值算法 → ORLM → SIRL → StepORLM → OPT-Engine → Agora-Opt → OR-Space，并延伸到 FMIP 等生成式 MILP warm start。这使其成为国际上“数学规划求解器 + OR foundation model + agent benchmark”最完整的研究生态之一。

优势：

- 掌握数值求解器、工业项目和 AI 建模三段；
- 公开了 ORLM、部分 GPU solver 和最新训练/benchmark 原型；
- 与 Stanford/Princeton/产业团队有稳定合作。

需要客观看待的风险：

- 若干工作与 COPT/Gurobi 绑定；
- benchmark、训练数据和评测可能来自同一生态，需外部 clean-room 复现；
- 部分最新仓库缺许可证、完整训练数据或独立基线；
- 目前未见公开的端到端 AI-native 大型电网求解系统。

10. 当前研究热点：2026 年的真实“热区”

热点 1：MILP foundation representation，而不只是大参数模型

真正问题是跨问题的变量/约束/目标语义、solver trace、多最优解、尺度和图同构。合成 MPS 矩阵的表面多样性不等于真实业务多样性。

热点 2：solver-in-the-loop RL 与过程监督

SIRL、StepORLM、Draft-and-Audit 将 solver 结果变成 reward，并逐步审核缺约束、错误数字和变量类型。但 outcome reward 与 process judge 都不能单独证明语义正确，必须加入独立测试和反例。

热点 3：预测-修正-认证

Apollo-MILP、Neural Diving、LNS、FMIP、WARP 均体现这一趋势：AI 给出高价值初始状态，经典算法收口。它是兼顾创新和安全的核心范式。

热点 4：连续-整数生成模型

从只预测 binary assignment 转向联合生成 integer、continuous、slack、dual 和 barrier state；FMIP 是代表。下一步是 feasibility-by-construction、多候选分布和 exact correction。

热点 5：求解器全生命周期 orchestration

单模块 branching 已不够。研究转向 presolve、cuts、node、heuristic、restart、数值算法、硬件、精度和预算的联合控制。

热点 6：低开销、可编译和可解释策略

Hybrid Learn2Branch、Symb4CO、LLM4Branch 说明生产环境可能更需要小 MLP、树模型或符号代码，而不是每个节点调用重 GNN。

热点 7：OOD、对称性、校准和理论

SymILO、GNN 表达能力、B&C 样本复杂度、PAC-Bayes L2O、数据驱动 LR 说明领域开始正视何时会失败，而不只展示平均提升。

热点 8：异构 CPU/GPU solver portfolio

硬件原生算法与 learned routing 的交叉正在形成。其优势是可测量、风险低、证书不变，并直接服务大规模能源优化。

热点 9：从单题到 workspace 和 lifecycle

OR-Space 的 Build/Revise/Explain 是早期信号。真实系统还需要 Clarify、Diagnose、Monitor、Regression、Rollback、Audit。

热点 10：算法发现从单策略转向 portfolio 和多保真评估

EoH-S、ShinkaEvolve、AlphaEvolve 表明多样性和系统 evaluator 是下一阶段壁垒；学术关键是控制自适应 benchmark 过拟合。

11. 关键研究 gaps：可以形成博士课题的问题

Gap 1：结构性 OOD 泛化

同一生成器下更大规模，不等于面对新约束结构、新拓扑、新规则或新 solver 版本仍有效。电网尤需 topology-OOD、time-OOD、extreme-event-OOD 和 rule-OOD。

Gap 2：实验协议不可比

常见问题包括不同 solver 版本、默认 solver 对精调 ML、硬件/线程不同、只报节点数或 kernel time、不计训练标签成本、只报成功案例。领域需要统一端到端 protocol。

Gap 3：solver 模块强耦合与因果归因

更好的 branching 可能破坏 cuts/heuristics/restart 的协同。需要多模块联合控制、反事实消融和 causal intervention。

Gap 4：训练投资回报未量化

应报告生成 strong-branch/cut/optimal-solution 标签花费多少 CPU/GPU-hours，以及需要多少次生产求解才能回本。

Gap 5：可行性、下界和证书

纯神经解通常没有 lower bound、infeasibility proof 或 optimality certificate。平均 gap 改善不能替代安全结论。

Gap 6：多最优解、退化和数值鲁棒性

单一最优标签造成监督冲突；KKT active set 突变、大 M、尺度不一致和病态线性系统会破坏学习与求导。

Gap 7：生成式求解的扩展瓶颈

$O(n^2)$ edge heatmap、多步网络调用、constraint guidance 成本、连续-整数校准和 repair 预算限制了超大实例。

Gap 8：foundation model 的语义真实性

.mps 图不包含设备类型、单位、规则文本、市场语义、时序和风险偏好。需要结构、文本、数据、trace 和 expert test 的多模态对齐。

Gap 9：随机、多阶段、动态和风险优化不足

当前 benchmark 仍以静态确定性 LP/MILP/TSP/VRP/MIS 为主；实际电网需要 stochastic/robust/chance/CVaR/rolling horizon。

Gap 10：安全标准与 bounded degradation 缺失

需要 OOD detector、confidence calibration、default fallback、shadow mode、p99 degradation、certificate 和故障审计。

Gap 11：自动建模的语义验证

目标值匹配无法识别错误但“碰巧等价”的模型。需要 typed IR、量纲检查、metamorphic test、反例生成和模型等价性证明。

Gap 12: 算法发现的统计有效性

在同一 benchmark 上自适应搜索数千次会产生 selection bias。需要 held-out evaluator、嵌套验证、family-level split 和统计修正。

Gap 13: 高成本/噪声 evaluator

真实数字孪生一次数小时，FunSearch 式搜索不可直接扩展。需要多保真 surrogate、主动分配预算、置信界和容错。

Gap 14: 开源、数据和供应链治理

无 LICENSE、NC 数据、闭源 solver、依赖污染和 LLM 代码执行沙箱是形成长期平台的现实障碍。

Gap 15: 电网静态优化与闭环控制割裂

Grid2Op/L2RPN 和 SCUC/SCOPF/OPF 学习社区评测目标不同。需要从 day-ahead schedule 到 real-time correction 的统一闭环基准。

12. 电网 AI-Native 优化：现状、机会与建议架构

12.1 现有工作的证据地图

工作	任务	贡献	开源/证据	主要限制
DeepOPF 系列	DC/SC-DC/AC OPF	神经代理、变量补全	论文为主	固定拓扑、分布内、认证不足
DC3	ACOPF/硬约束优化	differentiable completion/correction	Apache-2.0, ICLR 2021	correction 扩展性、仍是近似代理
DeepOPF+	DCOPF	preventive calibration, 论文报告 100% 测试可行和低 cost gap	ICLR 2023	线性/DC; 保证条件和数据域需严格满足
CANOS	ACOPF/N-1/大网	topology-aware GNN	论文, 无稳定官方代码	毫秒/低 gap 声称待独立复现
WARP	ACOPF IPM warm start	预测完整 primal-dual-barrier state	2026 预印本	无公开稳定仓库; 揭示 flat-start baseline 偏差
PGLearn + ML4OPF	AC/DC/SOC OPF 数据与代理	标准数据、residual、repair、模型接口	MIT	仍是研究工具; 真实拓扑/规则覆盖有限
GridFM DataKit	PF/OPF 数据生成	负荷、N-k、成本、导纳扰动	Apache-2.0	输入网络数据许可证仍需核查
UC 约束筛选	UC/SCUC	删除预测 inactive constraints, 再 constraint generation 补回	多篇论文	跨 ISO、极端事件与尾部性能不足
GNN-LSTM/少样本 SCUC	SCUC	变量/约束 reduction、warm start	原型	代码许可/安全证书不足
UnitCommitment.il	SCUC/AC/DC/N-1/随机	完整开源模型和独立 checker	BSD-3-Clause, 成熟	是基座, 不是 AI 模型
PowerModels / PGLib-OPF	OPF/凸松弛/基准	成熟模型和案例	BSD/CC Attribution	公开网架不等于真实运营分布
Grid2Op	时序运行和拓扑控制	RL/Gym、安全事件仿真	MPL-2.0	不是静态 OPF/SCUC solver benchmark

12.2 现阶段没有什么

尚未看到经过多篇顶会/期刊独立验证、同时满足以下条件的系统：

- 真实大型 SCUC/AC-SCUC/SCOPF;
- 多时段、储能、备用、N-1/N-k 和不确定性;
- 跨拓扑/跨运营商泛化;
- 可行性、下界/最优性界和失败回退;
- 公开训练数据、代码、许可证和统一硬件复现;

- 建模、求解、验证、解释、修订的完整生命周期。

这不是悲观结论，而是一个足够大的研究空白。

12.3 推荐系统架构



12.4 最有价值的电网研究命题

- 可认证 SCUC 线路/事故约束筛选。学习模型预测 inactive constraints; lazy constraint generation 自动补回误删项; 独立 checker 认证。
- 完整 primal-dual ACOPF warm start。不只预测 primal; 学习 dual、slack、barrier state 和不确定性, 并使用 corrected warm-start baseline。
- CPU/GPU/算法/presolve 自适应路由。保留原问题和证书, 直接优化端到端时间和尾部风险。
- 拓扑图 × 时间图的连续-整数生成。联合 commitment、dispatch、flow、reserve, 生成多候选, exact solver correction。
- Decision-focused 随机调度。用最终 UC/ED/储能/CVaR/备用 regret 训练负荷和新能源预测。
- Grid-Space/solver-trace benchmark。文档、数据、模型、修改请求、traces、证书、OOD split 共同开放。

13. 哪些方向最快拿到结果，哪些值得长期投入

13.1 6-12 个月优先级

方向	首个可信结果	顶级论文潜力	工业价值	风险	推荐
SCUC solver 配置/presolve/seperator	3-6 月	中高	很高	低	S
CPU/GPU 自适应 solver 路由	3-9 月	高	很高	低	S
可认证 SCUC constraint screening	4-8 月	高	很高	低中	S
GridBench/Grid-Space/trace benchmark	3-9 月	高	很高	中	S
DFL + ED/DCOPF/储能	3-6 月	中高	高	低	A
置信度 partial fixing / warm start	6-12 月	高	很高	中	A
电网结构化 LNS	6-12 月	高	很高	中	A
批量 DCOPF/QP 与 GPU SOCP-OPF	3-6 月	中高	高	中	A
自动建模语义 verifier	6-12 月	高	高	中	A

13.2 2-5 年深入方向

方向	学术潜力	工业潜力	主要难点
可认证 learning-augmented branch-and-cut	很高	很高	bounded degradation、OOD、跨版本
Grid Optimization Foundation Model	很高	很高	真实数据、跨拓扑、语义和证书
连续-整数 flow for SCUC/SCOPF	很高	高	规模、可行性、repair 预算
随机多时段 AC-SCUC/SCOPF	很高	很高	场景爆炸、非凸、整数和安全联合
全 solver 多模块 orchestration	很高	很高	长 horizon、模块耦合、异步反馈
学习型 KKT/Krylov/IPM 与多 GPU	高	很高	数值稳定、通信、混合精度
模型到求解器可信编译器	很高	很高	typed IR、等价证明、生命周期治理
安全闭环电网智能体	很高	很高	static optimization 与 real-time control 统一
算法发现的泛化理论	很高	中高	自适应评测、统计界、worst-case 保证

13.3 若只能做三条线

- 平台线：GridBench/Grid-Space + traces + independent checker。建立学术话语权和团队共享资产。
- 近程线：SCUC 可认证筛选 + solver 配置 + CPU/GPU 路由 + 安全 warm start。快速形成论文和工程收益。
- 远程线：拓扑/时序结构感知的连续-整数生成与 exact correction。形成可持续 3-5 年的核心算法方向。

三条线共享数据、模型、solver、checker 和评测协议，避免每名博士重复搭平台。

14. 建议的三阶段研究计划

阶段 I：0-9 个月，建立可信基准和快速成果

- 固定 UnitCommitment.jl、PGLib-OPF、PGLIB-UC、GO 公共案例版本；
- 建立 HiGHS、SCIP、Gurobi/COPT、cuPDLPx、cuOpt、MadNLP 的同硬件基线；
- 采集 presolve statistics、B&B traces、cuts、incumbent、bounds、KKT residual；
- 发布 topology/time/extreme-event OOD split；
- 完成 CPU/GPU 路由和 constraint screening 两个基线项目；
- 建立 reproducibility card、许可证清单和数据 lineage。

Go/No-Go: 若简单 LightGBM/RF/规则基线已达到 95% oracle 收益，优先做可靠性和 deployment，不盲目上大 GNN；若任何 ML 方案 p95 退化不可控，则先做拒答/回退。

阶段 II：9-24 个月，形成算法主线

- SCUC 置信度变量固定与结构化 LNS；
- ACOPF 完整 primal-dual-barrier warm start；
- DFL 的随机 UC/ED/储能；
- 自动建模 typed IR 和双验证器；
- 研究 solver 模块的因果交互和 multi-policy orchestration；
- 对算法发现采用 family-held-out evaluator 和多保真预算。

Go/No-Go: 只有在统一端到端 protocol 下显著降低 shifted geometric mean、timeout 和 p95/p99，且训练成本可在明确生产次数内回收，才继续扩大模型。

阶段 III：24-60 个月，建立领域级系统

- 跨 ACOPF/SCUC/SCOPF 的电网 foundation representation；

- 连续-整数-对偶联合生成;
- 多 GPU 场景/事故分解;
- exact-safe solver co-design;
- Grid2Op 闭环与 day-ahead/real-time 一体化;
- 可信编译、审计、版本化、回滚和 operator override。

终局目标：不是发布一个没有证书的“神经求解器 demo”，而是形成一个可被电网研究者和运营方审计、复现、回退和持续改进的 AI-native optimization stack。

15. 博士招聘与团队配置

15.1 建议首批 6-7 名博士

1. 数学规划与求解器博士

LP/MIP、branch-and-cut、decomposition、SCIP/HiGHS/COPT/Gurobi callbacks，负责可信基线和 exact-safe integration。

2. 电力系统优化博士

SCUC、ACOPF/SCOPF、储能、备用、N-1、市场规则，负责问题真实性和独立 checker。

3. 图学习与基础模型博士

MILP hypergraph、grid topology、跨任务预训练、对称性和 OOD。

4. 生成模型博士

discrete-continuous diffusion/flow、constraint guidance、多候选和 correction。

5. 可微优化与学习理论博士

implicit differentiation、DFL、regret、校准、PAC/online guarantee 和 bounded degradation。

6. GPU 数值计算博士

IPM/PDHG/Krylov、稀疏线性代数、预条件器、mixed precision、多 GPU 和异构路由。

7. 形式化验证与优化系统博士

typed IR、SMT/等价检查、程序沙箱、benchmark、数据 lineage、回归和审计。

15.2 必须配置的非博士角色

- 1 名资深 OR/solver 研究工程师;
- 1 名电网数据与仿真工程师;
- 1 名 ML systems/MLOps 工程师;
- 兼职法律/开源与数据治理支持;
- 与电网企业或调度机构的长期领域顾问。

15.3 共同基础设施

- 统一容器、solver 版本、硬件队列和随机种子;
- 统一数据版本、lineage 和许可证;
- 统一 wall-clock、energy、KKT、primal/dual integral 和尾部指标;
- 统一 OOD、极端事件和 failure audit;
- 统一 checker、fallback 和安全红线;
- 共享论文复现库，不让博士各自维护不可比的 fork。

16. 顶级研究应采用的实验协议

16.1 数据切分

- 不允许只随机切实例；
- 需要按模板 family、图同构簇、网架、日期/季节、规模、规则版本和极端事件切分；
- LLM 数据需记录 seed model、反向生成链和文本近邻；
- benchmark 不得进入长期 memory 或 self-improvement 数据。

16.2 求解器比较

- 同一 solver 版本、线程、时间、内存、容差和硬件；
- 经典 solver 也应合理调参，至少给 default、tuned 和 oracle portfolio；
- 报告训练/标签生成、模型加载、特征、推理、callback、repair 和认证的端到端时间；
- 给出禁用学习模块、随机策略、小模型/树模型消融。

16.3 指标

MILP/SCUC:

- shifted geometric mean solve time；
- primal/dual integral、gap trajectory；
- timeout、infeasible/unknown、p50/p95/p99；
- 节点、LP iterations、cuts、repair 次数；
- 训练成本回收次数和能源。

OPF/NLP:

- objective difference（明确是相对局部求解器还是全局下界）；
- equality/inequality residual、绝对/相对 KKT；
- primal/dual consistency 和 LMP/经济量；
- flat、primal-only、primal-dual 等公平 warm-start baseline；
- 失败率和恢复到可行解时间。

自动建模:

- 语法运行率、可行率、目标值准确率；
- semantic unit tests、missing/wrong constraint recall；
- formulation gap、big-M、节点数、数值条件和规模外 runtime；
- 澄清问题数量、拒答率、校准误差和人类修订时间。

算法发现:

- evaluator 调用数和总算力；
- family-held-out 性能、不同硬件/解释器/solver 版本；
- 多随机种子、nested validation、multiple testing 修正；
- 算法可读性、新颖性和人工证明/分析。

16.4 失败与安全报告

- 报告最坏案例而不只平均值；
- 说明 learned policy 何时拒答/回退；
- 保留原模型、候选、修复、证书和日志；
- 对生成代码做网络、文件、进程、依赖和资源沙箱；

- 对任何“100% feasibility”声明写明测试域、容差和保证条件。

17. 风险清单与立项判断

风险	表现	缓解措施
benchmark 过拟合/污染	公开分数高，真实任务骤降	family/time/topology split, 冻结 memory, clean-room 复评
solver baseline 不公平	“优于 Gurobi”但版本/调参/硬件不同	同协议重跑, default+tuned+oracle
训练成本不回本	离线标签极昂贵	报告 amortization, 优先弱监督/在线数据
可行但语义错误	错模型被正确求解	typed IR、独立语义测试、反例和人工签核
平均快但尾部危险	少数实例严重超时/违规	p95/p99、bounded degradation、fallback
GPU 精度/基础解不足	快速低精度但价格/证书不稳	KKT checker、crossover、mixed precision
ACOPF “最优”表述错误	只接近局部解	明确局部性, 使用下界/松弛或多起点
许可证/数据风险	公开仓库无法合法复用	建立 SBOM、license matrix、重新授权
LLM 代码执行风险	沙箱逃逸、依赖污染	hermetic sandbox、allowlist、无网络执行
多代理虚假共识	同一模型族重复同一错误	异构模型/规则/solver, 估计错误相关性

立项判断：该领域值得以 3-5 年持续投入形成研究方向，但应以“可信混合系统”和“电网严谨 benchmark”为中心，不以“端到端替代通用 solver”作为近期 KPI。

18. 结论

AI-Native 优化正在从零散的 learned heuristic 演化为覆盖建模、求解、验证、解释、算法发现和硬件调度的完整系统。其最大潜力来自重复实例分布和可执行数学反馈；最大风险来自结构 OOD、语义错误、数值不稳定、实验不可比和缺少证书。

最现实的技术范式是：

AI 负责提出、排序、选择和生成；数学优化负责修复、界定和证明；独立验证器负责拒绝错误；系统层负责校准、回退和审计。

对电网而言，这一范式尤其合适。以 SCUC/OPF/SCOPF 为核心，先建设高质量数据、solver trace、typed model 和独立 checker，再推进安全筛选、warm start、异构路由、生成模型和 foundation representation，可以同时获得短期论文、工程价值和长期学术壁垒。

附录 A：建议优先精读的 20 篇/项目

1. [Machine Learning for Combinatorial Optimization: A Methodological Tour d'Horizon](#)
2. [Exact CO with GCNs](#)
3. [Hybrid Models for Learning to Branch](#)
4. [What's Wrong with Deep Learning in Tree Search for CO](#)
5. [Solving MIPs Using Neural Networks](#)
6. [FMIP](#)
7. [LLM4Branch](#)
8. [OptNet](#)
9. [Differentiable Convex Optimization Layers](#)
10. [Smart Predict, then Optimize](#)

11. [DIFUSCO](#)
12. [FunSearch](#)
13. [EoH](#)
14. [ReEvo](#)
15. [OptiMUS](#)
16. [ORLM](#)
17. [SIRL](#)
18. [DC3](#)
19. [PGLearn/ML4OPE](#)
20. [Rapid Concurrent GPU-CPU UC](#)

附录 B：建议持续跟踪的平台

- [AI4OPT](#)
- [SCIP](#) / [PySCIPOpt](#) / [Ecole](#)
- [HiGHS](#)
- [ML4CO](#)
- [LLM4OR survey repository](#)
- [LLM4AD](#)
- [PowerModels](#) / [PGLib-OPE](#)
- [UnitCommitment.jl](#)
- [PGLearn](#) / [ML4OPE](#)
- [GridFM DataKit](#)
- [Grid2Op](#)
- [cuPDLPx](#) / [MPAX](#)
- [PDHCG-II](#) / [PDCS](#)
- [MadNLP](#) / [ExaModelsPower](#)

研究诚信说明： 本报告尽量采用论文和官方仓库的一手信息；对尚未同行评审、无代码、许可证不清、依赖闭源系统或存在评测污染风险的工作均作了明确降级。论文中的速度、准确率和 gap 只在原作者实验条件下成立，除非有统一环境复现，不应被解释为通用工业结论。